


Forecasting de Vendas no Varejo de Moda

Uma comparação entre modelos Catboost e LGBM
no horizonte de 7 dias



Vamos falar sobre...

1

**Características do
Varejo Moda**

EDA

Modelos ML

2

Ingestão

Processamento

Features

3

Treinamento

Catboost

Light GBM

4

**Métricas de
Avaliação**

Limitações

5

Próximos Passos

**Deploy
MLOps**

Estudos Avançados

Características do Varejo de Moda

Portfólios Extensos

Ciclos Curtos de coleção

Sazonalidade pronunciada (festas, liquidações)

SKUs novos

Picos de campanhas (outliers)


Ruído diário, efeitos de dia da semana

Qual a sazonalidade de vendas?

Qual é o comportamento dos SKUs?

EDA


Comportamento das Vendas no Período



**Período Jan à Abr 2024
>5.500 SKUs**

35k peças seg a sexta
53k peças fds
1,5k SKUs vendidos dia

Clusterização dos SKUs (ADI vs CV^2)



Fonte: Syntetos, Boylan e Croston (2005)

Intervalo médio vendas (ADI) x Coef. Variação (CV)

- ~ 68% Longos períodos sem venda, porém quando ocorre a venda o volume é frequente
- ~ 30% Venda quase diária, com volume mais baixo
- < 1% venda diária com muita volatilidade
- < 1% poucas vendas e volume imprevisível

Escolha do Modelo

REGULARES: (ADI ↓, CV² ↓)

- ETS / Holt-Winters
- Auto-ARIMA / SARIMA

- LightGBM
- CatBoost

- PatchTST (Transformer para séries)
- N-HITS / N-BEATSx

INTERMITENTE: (ADI ↑, CV² ↓)

- Croston clássico
- TSB (Teunter-Syntetos-Babai)

- Estratégia 2-etapas
classificador + LGBM

- DeepAR-ZI
- Prophet

ERRÁTICO: (ADI ↓, CV² ↑)

- STL + TBATS (captura picos)

- CatBoost / LightGBM

- Temporal Fusion
Transformer (TFT)
- WaveNet / TCN

IRREGULAR: (ADI ↑, CV² ↑)

- Croston ajustado a variância
- ADIDA (agrega → desagrega)

- Hierarchical Top-Down + LGBM
(treina no agregado, aloca por SKU)

- Simulação Monte Carlo
alimentada por forecast
agregado

- N-HITS global + máscara de
zeros

98% DOS DADOS



Catboost e LGBM

Catboost x LightGBM

“KIT PRONTO”

ML Gradient Boosting

- **Frameworks de última geração** (Yandex x Microsoft)
 - não precisa programar o algoritmo do zero, ajustes automáticos
 - tratamentos de variáveis categóricas, faltantes, desbalanceadas
- **Velocidade e Escala** >> treinam milhões de registros em minutos pq usam paralelismo/compressão
- **Deploys** >> artefatos compactos >> API
- **Governança** >> Integração nativa com ML FLOW do Databricks (versionamento, retreino, monitoramento)
- Treina um modelo em 3 linhas de código.

Pipeline

Crisp-ML

1

Ingestão Pré-processamento

Gravação dado em Delta

Logs

Agrupamento de
dados duplicados

Preenchimento de datas
com zero para dados
faltantes (gap-filling)

2

Features

Logs

Gera lags
(1, 7, 14dd)

Gera médias móveis
(7, 14, 30dd)

Variáveis de Calendário
(dia semana / fds / mês)

3

Treino/Teste

CATBOOST/LGBM

Treina baseline e ajusta
dados cross validação

Treina modelo Final

Prevê horizonte de 7 dias

4

Avaliação Modelo

Métricas:

RMSE
MAE

MAPE(%)
WMAPE(%)

R2

Escolha do Modelo para
produção

5

Deploy Observability

Próximos Passos

Features

LAG em dias : 1, 7, 14 (reconhecimento de padrões - quanto vendeu?)

No geral, o modelo de árvore não sabe que o registro de ontem é importante. Então eu precisaria informar p/ ele.

Médias Móveis : 7, 14, 30 (suavizar o ruído/identificar a tendência)

* Tirar o efeito dos picos de sale, ou vales de ruptura. Filtra as flutuações

Calendários: (recorrência, efeito de mês e feriado)

- Dias da semana (1 à 7)
- Final de Semana (0 ou 1)
- Mês (1 à 12)

Treino

Dados de Entrada:

- Lag
- Médias móveis
- Flags
- Calendários

Treino x Validação:

- Quebrei as séries em 5 Splits (pares de treino/teste)
- Em cada split treino acumula dados antigos e teste avança para próximo bloco futuro
- Cada fold/iteração treina em “blocos” cumulativos e valida num bloco futuro (16% dos dados por fold)

Validação Cruzada:

- RMSE médio entre os 5 folds
- Gerei LOG de performance por FOLD

Hiperparâmetros: (standard)

- VC: (LGBM x Catboost)
 - 100 árvores de iteração (custo computacional)
 - 0,1 learning_rate (velocidade de validação)
 - 42 randon_state (sequencia numeros aleatorios)
 - 5 folds
- FInal: (Catboost)
 - 200 árvores de iteração
 - 0,05 learning_rate
 - 42 randon_state
 - horizonte 7 dias

Logs Treino

LGBM

```
2025-07-16 08:08:18 [INFO] pipeline - Closing down clientserver connection
2025-07-16 08:08:19 [INFO] pipeline - ===== INÍCIO LIGHTGBM =====
2025-07-16 08:08:19 [INFO] pipeline - Dados brutos carregados: (230704, 14)
2025-07-16 08:08:22 [INFO] pipeline - Features geradas: (230704, 14)
2025-07-16 08:08:22 [INFO] pipeline - Colunas de feature: ['is_imputed', 'was_imputed', 'lag_1', 'lag_7', 'lag_14', 'roll_mean_7', 'roll_m
2025-07-16 08:08:23 [INFO] pipeline - fold 1 RMSE 5.1329
2025-07-16 08:08:24 [INFO] pipeline - fold 2 RMSE 6.2467
2025-07-16 08:08:25 [INFO] pipeline - fold 3 RMSE 79.7516
2025-07-16 08:08:26 [INFO] pipeline - fold 4 RMSE 4.9785
2025-07-16 08:08:28 [INFO] pipeline - fold 5 RMSE 4.8937
2025-07-16 08:08:28 [INFO] pipeline - CV RMSE média 20.2007
```

CATBOOST

```
2025-07-16 08:08:50 [INFO] pipeline - ===== INÍCIO CATBOOST =====
2025-07-16 08:08:51 [INFO] pipeline - Dados brutos carregados: (230704, 14)
2025-07-16 08:08:53 [INFO] pipeline - Features geradas: (230704, 14)
2025-07-16 08:08:53 [INFO] pipeline - Colunas de feature: ['is_imputed', 'was_imputed', 'lag_1', 'lag_7', 'lag_14', 'roll_mean_7', 'roll_m
2025-07-16 08:08:54 [INFO] pipeline - fold 1 RMSE 5.2134
2025-07-16 08:08:54 [INFO] pipeline - fold 2 RMSE 6.3197
2025-07-16 08:08:55 [INFO] pipeline - fold 3 RMSE 80.1870
2025-07-16 08:08:56 [INFO] pipeline - fold 4 RMSE 5.3907
2025-07-16 08:08:57 [INFO] pipeline - fold 5 RMSE 5.2189
2025-07-16 08:08:57 [INFO] pipeline - CV RMSE média 20.4659
2025-07-16 08:08:59 [INFO] pipeline - Modelo salvo em data/models/catboost_model.cbm
```

Métricas de Avaliação

p/ Séries Temporais

RMSE: Raiz do Erro Quadrático Médio

- Desvio médio, que penaliza maiores erros (muito bom para outliers)
- Em unidade de venda, quanto menor melhor.

MAE: Erro Absoluto Médio

- Desvio médio em unidades originais (defasagem real x previsto)

EX.: MAE 3 >> em média o modelo erra 3 peças por dia.

MAPE: Erro % Absoluto Médio

- % médio de erro entre o previsto e real

EX.: MAPE de 20% significa que em média o forecast se diferencia 20% do real

- Limitação se $y = 0$, cálculo instável

WMAPE: Erro % Médio Ponderado

- Erro absoluto de todas as previsões pela soma de todas as vendas
- Robustez quando há muitas vendas zeradas/sku de baixo volume, não divide erro individual

R2: Coeficiente de Determinação

- Mede a fração de variabilidade que o modelo consegue explicar
- Não pode ser medido sozinho

Modelo	RMSE	MAE	MAPE (%)	WMAPE (%)	R ²	Comentário rápido
lgbm	7,81	2,97	16,21	19,45	0,96	melhor MAE e menores MAPE/WMAPE → erros absolutos e relativos mais baixos em média
catboost	7,26	3,18	26,60	20,84	0,97	menor RMSE e maior R ² → penaliza menos grandes desvios, “explica” ligeiramente mais variância
reconciled	7,30	3,04	20,52	19,92	0,97	intermediário em quase tudo, combina previsões para balancear erros grandes e pequenos

Limitações Atuais

Não captura o Erro por SKU
Não mensura o Erro por classificações de produto

Próximos Passos

- Avaliar como o modelo se comporta por SKU (resíduo)
 - Avaliar como o modelo se comporta por cluster de produto
 - Agrupar por categorias
-
- Para modelos erráticos, treinar Top Down e depois distribuir por SKU
 - Estudar o Learning Transfer com modelos pré-treinados prontos para receber novos SKUs...
 - Experimentação... Treinar os modelos a partir do cluster, mesclar mais de um tipo de Modelo

Modelo em MVP

- Até o Momento, temos os seguintes arquivos em produção e funcionais:

Dashboard:

<https://sales-forecasting-for-sku.streamlit.app/>

GitHub:

https://github.com/betinaschilling/project_time_series_forecasting